

**Министерство науки и высшего образования Российской Федерации ФЕДЕРАЛЬНОЕ
ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО
ОБРАЗОВАНИЯ**

«Национальный исследовательский университет ИТМО»

(Университет ИТМО)

Факультет прикладной информатики

Образовательная программа Мобильные и сетевые технологии

Направление подготовки 09.03.03 Мобильные и сетевые технологии

О Т Ч Е Т

По дисциплине «Современные инструменты анализа данных»

Лабораторная работа №1 «Уменьшение размерности данных и сравнение методов»

Обучающийся: Данилова Анастасия Алексеевна СИАД К33 1.2

Проверил: Добренко Наталья Викторовна

Санкт-Петербург,

2025

1. Цель работы.

Освоить практические навыки работы с методами уменьшения размерности данных, такими как PCA и t-SNE, а также интерпретации их результатов.

2. Введение

Уменьшение размерности данных – это подход к упрощению сложных наборов данных путем сокращения количества переменных при сохранении наиболее важной информации. Это позволяет облегчить обработку, анализ и визуализацию данных.

Метод главных компонент (PCA) – это линейный метод уменьшения размерности, который ищет направления максимальной дисперсии в данных. Он преобразует исходные переменные в новый набор некоррелированных переменных, называемых главными компонентами.

t-SNE (t-distributed Stochastic Neighbor Embedding) – это нелинейный метод уменьшения размерности, который особенно эффективен для визуализации высокоразмерных данных. Он стремится сохранить локальную структуру данных, уделяя особое внимание сохранению близости между точками в пространстве меньшей размерности.

3. Задание.

1. Сбор и предобработка данных: а) Загрузить данные о жанрах музыки (Prediction of music genre). б) Провести предварительную обработку данных:
 - Заменить нечисловые данные на числовые (создать шкалу соответствия);
 - Удалить переменные с нулевой дисперсией;
 - Оставить 10–12 параметров. в) Построить корреляционную матрицу и дать интерпретацию выявленным зависимостям. г) Построить график каменистой осыпи.
2. Реализация и применение PCA: а) Реализовать алгоритм PCA (можно использовать `sklearn.decomposition.PCA`). б) Вычислить объясненную дисперсию для каждой компоненты. в) Вычислить процент объясненной дисперсии для первых n компонент. г) Построить проекцию данных на новое пространство;
3. Реализация и применение t-SNE: а) Реализовать алгоритм t-SNE (можно использовать `sklearn.manifold.TSNE`). б) Применить t-SNE с разными значениями перплексии. в) Визуализировать результаты;
4. Сравнительный анализ: а) Сравнить результаты PCA и t-SNE на исследуемых данных. б) Проанализировать преимущества и недостатки каждого метода в контексте ваших данных.

4. Выполнение.

4.1. Предобработка данных

На этом этапе произведен импорт датасета, убраны неинформативные столбцы (`artist_name`, `track_name`, `obtained_date`), которые не пригодятся в PCA. Также были удалены переменные с нулевой дисперсией. Категориальные признаки были преобразованы:

```

from sklearn.preprocessing import LabelEncoder

categorical_cols = ["key", "mode", "music_genre"]
le_dict = {}

for col in categorical_cols:
    if col in df.columns:
        le = LabelEncoder()
        df[col] = le.fit_transform(df[col].astype(str))
        le_dict[col] = le

```

Для 10–12 числовых признаков были отобраны музыкальные параметры:

```


feature_candidates = [
    'acousticness', 'danceability', 'duration_ms', 'energy',
    'instrumentalness', 'liveness', 'loudness', 'speechiness',
    'tempo', 'valence', 'popularity', 'key', 'mode'
]

```

Код в секторе предобработки выполняет следующие задачи:

1. Загружает файл
2. Удаляет строки, которые не нужны для анализа
3. Превращает категориальные признаки в числа
4. Удаляет колонки без дисперсии
5. Выбирает 10–12 полезных музыкальных признаков
6. Масштабирует данные для PCA и t-SNE

Далее была построена корреляционная матрица и проведена её интерпретация:



Исходя из полученного графика были сделаны следующие выводы:

Основные наблюдения:

- Сильная отрицательная связь:
 - acoustictness - energy (около -0.5 или ниже).

Вывод: акустичные треки редко бывают энергичными.

- acoustictness - loudness.

Вывод: Громкие треки обычно не акустичные.

- Сильная положительная связь:
 - energy - loudness (сильно >0.6).

Вывод: энергичные треки, как правило, громкие.

- Умеренная положительная связь:
 - danceability - valence.


Вывод: чем более "веселый" трек, тем чаще он танцевальный.

- Почти отсутствующая корреляция:
 - key
 - mode

Вывод: Тональность почти не влияет на остальные параметры.

На основе этих наблюдений можно сказать, что структура PCA линейно зависима.

Далее был построен график каменной осыпи:



На основе полученного графика были сделаны следующие выводы:

1-я компонента объясняет больше всего (около 28-29%)

2-я - ещё около 10%

Далее идёт постепенное снижение.

Вывод:

- Первые 2–3 компоненты содержат большую часть информации.
- После 6–7-й компоненты вклад становится очень маленьким, значит можно отбросить.

4.2. Реализация и применение PCA

Используемая библиотека и параметры:

Для реализации метода главных компонент использовалась библиотека `sklearn.decomposition.PCA`.

Основные параметры:


`n_components = None` - для анализа всех компонент

Для финальной визуализации использовалось `n_components = 2`

Данные предварительно масштабировались с помощью `StandardScaler`

Анализ объясненной дисперсии

Были построены графики:



На основе анализа графиков объясненной дисперсии можно определить:

- Для визуализации достаточно 2 компонент (38.7% дисперсии)
- Для задач классификации рекомендуется 6–8 компонент (70-84% дисперсии)
- Для полного сохранения информации требуется 10 компонент (93.6% дисперсии)

Доля дисперсии, сохраняемая первыми компонентами:

- PC1: 28.4% общей дисперсии
- PC2: 10.3% общей дисперсии
- PC1 + PC2: 38.7% общей дисперсии
- Первые 5 компонент: 62.6% общей дисперсии
- Первые 10 компонент: 93.6% общей дисперсии

Интерпретация компонент



Какие признаки вносят наибольший вклад в каждую компоненту:

PC1 (28.4% дисперсии) - "Энергетический профиль":

- Положительные нагрузки: loudness (0.88), energy (0.85)
- Отрицательные нагрузки: acousticness (-0.82), instrumentalness (-0.65)
- Умеренные: danceability (0.58), valence (0.53), popularity (0.48)

PC2 (10.3% дисперсии) - "Танцевальность и темп":

- Положительные: danceability (0.54), popularity (0.45)
- Отрицательные: tempo (-0.41), liveness (-0.39), energy (-0.36)

PC3 (8.5% дисперсии) - "Структурные характеристики":

- Положительные: mode (0.68), speechiness (0.43), key (0.43)


PC4 (7.9% дисперсии) - "Живость исполнения":

- Положительные: liveness (0.60), key (0.46), speechiness (0.47)

Смысловая интерпретация главных компонент:

1. PC1 противопоставляет громкие и энергичные треки (электронная музыка, рок) акустическим и инструментальным композициям (классика, джаз)
2. PC2 разделяет треки по танцевальности и популярности - популярные танцевальные треки с одной стороны и быстрые "живые" композиции с другой
3. PC3 отражает структурную сложность - характеризует треки со сложной музыкальной структурой и речевыми элементами
4. PC4 связана с характером исполнения - выделяет "живые" записи с элементами речи

Визуализация в пространстве PCA



Насколько хорошо разделяются жанры:

Визуализация в пространстве первых двух главных компонент демонстрирует:

- Частичное разделение музыкальных жанров по осям PC1 и PC2
- Наиболее обособленные кластеры соответствуют крайним значениям по компонентам
- Перекрывающиеся области свидетельствуют о наличии общих характеристик между разными жанрами
- PC1 эффективно разделяет жанры по энергетическому профилю
- PC2 обеспечивает дополнительное разделение по танцевальным характеристикам

Выводы о структуре данных:

1. Данные обладают выраженной внутренней структурой, что подтверждается значительным вкладом первых компонент
2. Музыкальные жанры частично сепарабельны в пространстве главных компонент
3. Наблюдается логичная группировка характеристик: энергетические параметры объединяются в PC1, танцевальные - в PC2
4. 38.7% дисперсии, сохраняемые первыми двумя компонентами, являются удовлетворительным показателем для визуализации и первичного анализа
5. Метод PCA подтвердил осмысленность исходных признаков и их способность дифференцировать музыкальные жанры

Полученные результаты свидетельствуют о том, что метод главных компонент эффективно выявляет основные закономерности в музыкальных характеристиках и может быть успешно использован для уменьшения размерности данных.

4.3. Реализация и применение t-SNE

Реализация t-SNE


Используемые параметры:

Для реализации t-SNE использовалась библиотека `sklearn.manifold.TSNE` со следующими параметрами:

- `n_components = 2` - уменьшение размерности до 2D для визуализации
- `random_state = 42` - для воспроизводимости результатов
- `perplexity = [5, 30, 50]` - тестирование различных значений перплексии
- `n_iter = 1000` - количество итераций оптимизации
- `learning_rate = 'auto'` - автоматический подбор скорости обучения
- `init = 'random'` - случайная инициализация

Важное замечание: В связи с ограниченной вычислительной мощностью и большим объемом исходных данных (более 50,000 наблюдений), анализ проводился на случайной выборке из 5,000 наблюдений. Это стандартный подход при работе с t-SNE для больших датасетов, позволяющий сохранить репрезентативность данных при разумном времени вычислений.

Влияние параметра перплексии



Анализ изменения кластеризации:

Перплексия = 5:

- Наблюдается сильная фрагментация данных на множество мелких кластеров
- Локальная структура сохраняется очень хорошо
- Глобальная структура практически отсутствует
- Множество изолированных маленьких групп, что может указывать на переобучение

Перплексия = 30:

- Оптимальный баланс между локальной и глобальной структурой
- Кластеры становятся более крупными и четкими
- Сохраняется разделение между жанрами при лучшей видимости общей структуры
- Наиболее интерпретируемый результат

Перплексия = 50:


- Усиление глобальной структуры данных
- Кластеры становятся более размытыми
- Ухудшается разделение между близкими жанрами
- Увеличивается расстояние между крупными группами

Выбор оптимального значения:

На основе анализа визуализаций оптимальным значением перплексии для данного датасета является 30. При этом значении достигается наилучший баланс между:

- Сохранением локальной структуры данных
- Отображением глобальных закономерностей
- Четкостью кластеров музыкальных жанров
- Интерпретируемостью результатов

4.4. Сравнительный анализ



Сравнение PCA и t-SNE

Критерий	PCA	t-SNE
Сохранение глобальной структуры	Высокое	Низкое
Сохранение локальной структуры	Низкое	Высокое
Интерпретируемость	Высокая	Низкая
Вычислительная сложность	Быстрее $O(n^3)$	Медленнее $O(n^2)$
Качество разделения жанров	Умеренное (38.7% дисперсии)	Хорошее
Стабильность результатов	Детерминирован	Стохастичен
Масштабируемость	Хорошая	Ограниченная

Преимущества и недостатки

Когда использовать PCA:

Преимущества PCA:

- Высокая интерпретируемость компонент
- Быстрое выполнение даже на больших датасетах
- Сохраняет глобальную структуру данных
- Детерминированные результаты (воспроизводимость)
- Эффективен для линейных зависимостей

Рекомендуется использовать PCA когда:

- Требуется интерпретация влияния признаков
- Работа с большими объемами данных (>10,000 наблюдений)
- Необходимость быстрой предобработки для других алгоритмов
- Анализ линейных зависимостей в данных
- Задачи сжатия данных с минимальной потерей информации

Когда использовать t-SNE:

Преимущества t-SNE:

- Отличная визуализация кластеров
- Сохранение локальной структуры
- Эффективен для нелинейных данных
- Хорошее разделение сложных классов

Рекомендуется использовать t-SNE когда:

- Визуализация многомерных данных
- Анализ кластерной структуры
- Работа с нелинейными зависимостями
- Exploratory Data Analysis (разведочный анализ)
- Объем данных не превышает 10,000 наблюдений

Рекомендации для разных типов задач:

Для музыкального анализа жанров:

- PCA: для анализа влияния музыкальных характеристик на жанры, feature engineering
- t-SNE: для визуализации и исследования кластерной структуры жанров

Для промышленного применения:

- PCA: в музыкальных рекомендательных системах для уменьшения размерности
- t-SNE: для анализа музыкальных библиотек и создания тематических плейлистов

Для исследовательских целей:

- Комбинированный подход: PCA для initial analysis, затем t-SNE для детальной визуализации

5. Выводы

Основные результаты работы:

1. Успешная реализация методов уменьшения размерности PCA и t-SNE для анализа музыкальных данных
2. PCA показал, что первые две компоненты объясняют 38.7% дисперсии, с четкой интерпретацией: PC1 - "Энергетический профиль", PC2 - "Танцевальность"
3. t-SNE продемонстрировал значительно лучшее визуальное разделение музыкальных жанров с оптимальной перплексией 30
4. Выявлены сильные корреляции между музыкальными характеристиками (loudness-energy: 0.85, acousticness-energy: -0.72)
5. Подтверждена эффективность уменьшения размерности для анализа и визуализации музыкальных данных

Практическая значимость:

1. Для музыкальной индустрии: методы позволяют анализировать и визуализировать музыкальные библиотеки, выявлять паттерны
2. Для рекомендательных систем: уменьшение размерности улучшает эффективность алгоритмов рекомендаций
3. Для музыкальных стриминговых сервисов: возможность автоматической классификации и тегирования треков
4. Для исследователей: инструменты для анализа музыкальных предпочтений и тенденций

Проведенная работа подтвердила эффективность методов уменьшения размерности для анализа музыкальных данных и создала основу для дальнейших исследований в области музыкальной аналитики.

Ссылка на github с кодом в Google Collab:

https://github.com/ndanilova/Data_Analysis/tree/main/lab1