

**Министерство науки и высшего образования Российской Федерации ФЕДЕРАЛЬНОЕ
ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО
ОБРАЗОВАНИЯ**

«Национальный исследовательский университет ИТМО»

(Университет ИТМО)

Факультет прикладной информатики

Образовательная программа Мобильные и сетевые технологии

Направление подготовки 09.03.03 Мобильные и сетевые технологии

О Т Ч Е Т

По дисциплине «Современные инструменты анализа данных»

Лабораторная работа №2 «Кластеризация данных»

Обучающийся: Данилова Анастасия Алексеевна СИАД К33 1.2

Проверил: Добренко Наталья Викторовна

Санкт-Петербург,

2025

1. Цель работы.

Освоить практическое применение методов кластеризации данных, в частности алгоритмов К-средних и DBSCAN, на различных наборах данных

2. Введение.

Кластеризация – это метод машинного обучения без учителя, направленный на разделение набора объектов на группы (кластеры) таким образом, чтобы объекты внутри одной группы были более похожи друг на друга, чем на объекты из других групп.

Метод К-средних – это итеративный алгоритм, который разбивает набор данных на К предопределенных непересекающихся подгрупп (кластеров), где каждая точка данных принадлежит только одному кластеру.

Метод DBSCAN (Density-Based Spatial Clustering of Applications with Noise) – это алгоритм кластеризации, основанный на плотности. Он группирует вместе точки, которые находятся близко друг к другу в областях высокой плотности, отмечая точки в областях с низкой плотностью как выбросы.

3. Задание.

1. Изучите теоретический материал и примеры в Jupyter Notebook по [ссылке](#);
2. Используйте метод К-средних и метод DBSCAN на самостоятельно сгенерированной выборке:
 - Создайте выборку с помощью функции [make_blobs](#), задав количество кластеров не менее 4 через параметр centers;
 - Примените оба метода к полученным данным;
 - Визуализируйте результаты.
3. Примените методы К-средних и DBSCAN к датасету **penguins**:
 - Загрузите датасет с [Kaggle \(Clustering Penguins Species\)](#);
 - Проведите предварительный анализ данных;
 - Примените оба метода кластеризации;
 - Визуализируйте и интерпретируйте результаты.
4. Для каждого метода постройте графики и проанализируйте результаты:
 - Для К-средних используйте метод локтя и коэффициент силуэта для определения оптимального числа кластеров, сравните получившиеся варианты кластеризации;
 - Для DBSCAN поэкспериментируйте с параметрами eps и min_samples.

4. Выполнение

4.1. Кластеризация на сгенерированных данных

Создание набора данных

Описание: для генерации набора данных использовалась функция `make_blobs` из библиотеки `sklearn.datasets`. Было создано 4 явно разделимых кластера с добавлением небольшого шума для имитации реальных данных.


Код:

```
X, y_true = make_blobs(n_samples=300, centers=4, cluster_std=0.60,
                        random_state=42, center_box=(-10, 10))
```

Результаты:

- Размерность данных: (300, 2) - 300 точек с двумя признаками
- Количество истинных кластеров: 4

Визуализация: на scatter-plot сгенерированных данных четко видны 4 компактных кластера с небольшим перекрытием, что является идеальным случаем для тестирования алгоритмов кластеризации.



Применение метода K-means

Определение оптимального K:

Для определения оптимального числа кластеров использовались два метода:

1. Метод локтя - анализ зависимости внутрикластерной дисперсии (inertia) от числа кластеров
2. Коэффициент силуэта - оценка качества кластеризации для разных K

Результаты подбора K:

ПРИМЕНЕНИЕ МЕТОДА K-MEANS

Подбор оптимального числа кластеров...

K=2: inertia=9051.82, silhouette=0.615

K=3: inertia=1773.74, silhouette=0.799

K=4: inertia=203.89, silhouette=0.876

K=5: inertia=184.41, silhouette=0.755

K=6: inertia=165.72, silhouette=0.610

K=7: inertia=148.07, silhouette=0.454


K=8: inertia=129.73, silhouette=0.341

Вывод: Оптимальное число кластеров - K=4, так как при этом значении:

- Наблюдается "изгиб" на графике метода локтя
- Коэффициент силуэта достигает максимального значения (0.876)

Кластеризация: Применен алгоритм K-means с K=4.

Визуализация результатов: на scatter-plot видно, что K-means успешно разделил данные на 4 кластера, центроиды которых расположены в центрах скоплений точек.



Коэффициент силуэта: 0.876 - отличный результат, свидетельствующий о высоком качестве кластеризации.

Применение метода DBSCAN

Подбор параметров:

Для подбора оптимальных параметров DBSCAN использовался:

- График расстояний до k-го соседа для определения параметра ϵ
- Перебор различных комбинаций ϵ и $\min_samples$

Результаты экспериментов с параметрами:

ПРИМЕНЕНИЕ МЕТОДА DBSCAN

Экспериментируем с параметрами DBSCAN:


eps=0.3, min_samples=3: кластеров=13, шум=43, силуэт=0.041
eps=0.3, min_samples=4: кластеров=7, шум=66, силуэт=0.315
eps=0.3, min_samples=5: кластеров=5, шум=85, силуэт=0.339
eps=0.5, min_samples=3: кластеров=4, шум=7, силуэт=0.828
eps=0.5, min_samples=4: кластеров=5, шум=8, силуэт=0.675
eps=0.5, min_samples=5: кластеров=4, шум=13, силуэт=0.798
eps=0.7, min_samples=3: кластеров=4, шум=4, силуэт=0.834
eps=0.7, min_samples=4: кластеров=4, шум=4, силуэт=0.834
eps=0.7, min_samples=5: кластеров=4, шум=4, силуэт=0.834
eps=1.0, min_samples=3: кластеров=4, шум=1, силуэт=0.773
eps=1.0, min_samples=4: кластеров=4, шум=1, силуэт=0.773
eps=1.0, min_samples=5: кластеров=4, шум=1, силуэт=0.773

Лучшие параметры: eps=0.7, min_samples=3

Результаты кластеризации:

- Найдено кластеров: 4
- Шумовых точек: 4
- Коэффициент силуэта: 0.834

Визуализация: на графике видно, что DBSCAN успешно выделил 4 основных кластера и идентифицировал 4 точки как шумовые.



Сравнение и анализ результатов на сгенерированных данных

СРАВНЕНИЕ И АНАЛИЗ РЕЗУЛЬТАТОВ

СВОДКА РЕЗУЛЬТАТОВ:

Метод	Кластеров	Шум	Силуэт
Истинные	4	0	-
K-means	4	0	0.876
DBSCAN	4	4	0.834

Сравнительный анализ:

1. K-means:

- Показал отличные результаты на идеально разделимых данных
- Нашел точное количество кластеров (4)
- Не выделяет шумовые точки - принудительно относит все точки к кластерам
- Коэффициент силуэта (0.876) немного выше, чем у DBSCAN
- Хорошо справляется с шарообразными кластерами правильной формы

2. DBSCAN:


- Также успешно определил 4 основных кластера
- Выделил 4 шумовые точки, что демонстрирует его устойчивость к выбросам
- Коэффициент силуэта (0.834) немного ниже, но все равно высокий
- Более универсален для кластеров произвольной формы
- Требует тщательного подбора параметров

3. Общее сравнение:

- Оба метода показали отличные результаты на сгенерированных данных
- K-means демонстрирует немного лучшие результаты по коэффициенту силуэта
- DBSCAN обладает важным преимуществом - способностью явно выделять шум

4. Обработка шума:

- K-means: принудительно включает все точки в кластеры
- DBSCAN: явно идентифицирует и маркирует шумовые точки



Выводы по разделу:

На сгенерированных данных оба алгоритма кластеризации показали высокую эффективность. K-means немного превзошел DBSCAN по коэффициенту силуэта, что объясняется идеальной сферической формой кластеров, для которой K-means оптимизирован. DBSCAN продемонстрировал важное преимущество в виде выделения шумовых точек, что делает его более robust для работы с реальными данными, содержащими выбросы.

Оба метода успешно справились с основной задачей - определили правильное количество кластеров (4), что подтверждает их применимость для решения задач кластеризации.

4.2. Кластеризация на реальных данных (Dataset Penguins)

Предварительный анализ и обработка данных

Первичный обзор:

- Размер датасета: 344 строки, 5 столбцов
- Признаки: culmen_length_mm, culmen_depth_mm, flipper_length_mm, body_mass_g, sex


Первые 5 строк данных:

Первые 5 строк:

	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g	sex
0	39.1	18.7	181.0	3750.0	MALE
1	39.5	17.4	186.0	3800.0	FEMALE
2	40.3	18.0	195.0	3250.0	FEMALE
3	NaN	NaN	NaN	NaN	NaN
4	36.7	19.3	193.0	3450.0	FEMALE

Описательная статистика до обработки:

- Средняя длина клюва: 43.92 мм
- Средняя глубина клюва: 17.15 мм
- Средняя длина плавника: 214.01 мм (искажена выбросами)
- Средняя масса тела: 4201.75 г



Анализ пропущенных значений

Выявленные пропуски:

- Числовые признаки: по 2 пропуска в каждом столбце
- Категориальный признак sex: 9 пропусков + 1 некорректное значение '1'


Уникальные значения в столбце sex:

- MALE: 169
- FEMALE: 165
- Пропуски: 9
- Некорректное значение: 1

Анализ выбросов и аномалий

Критические аномалии:

- flipper_length_mm = 5000.0 - явная ошибка измерения
- flipper_length_mm = -132.0 - отрицательное значение, физически невозможное
- body_mass_g > 6000 - 2 записи с аномально высокой массой



Выявленные аномальные записи:

Строка с отрицательным flipper_length_mm:

culmen_length_mm: 34.6, culmen_depth_mm: 21.1, flipper_length_mm: -132.0, body_mass_g: 4400.0, sex: MALE

Строка с flipper_length_mm = 5000.0:

flipper_length_mm: 5000.0, body_mass_g: 4250.0

Обработка данных

Обработка выбросов:

- Заменено аномальных значений в flipper_length_mm: 2
- Установлены разумные границы для каждого признака


Обработка пропущенных значений:

- Числовые признаки: заполнение медианой

- Категориальный признак sex: заполнение наиболее частым значением

Кодирование категориальных признаков:

- sex преобразован в числовой формат: FEMALE → 0, MALE → 1



Результаты обработки

Обновленная статистика:

- Все пропуски устранены
- Размер данных сохранен: 344 строки
- Выбросы корректно обработаны
- flipper_length_mm: исправлено с 214.01 до 200.91 мм (реалистичное значение)


Корреляционный анализ:

- Наибольшая корреляция с полом: body_mass_g (0.41)
- Сильная взаимосвязь: flipper_length_mm и body_mass_g (0.87)
- Умеренная отрицательная корреляция: culmen_depth_mm и body_mass_g (-0.47)

Масштабирование признаков

Применен StandardScaler:

- Все признаки приведены к единому масштабу
- Среднее значение: ~0, стандартное отклонение: 1



Финальные данные для кластеризации:

- Размер: 344×5
- Признаки: culmen_length_mm, culmen_depth_mm, flipper_length_mm, body_mass_g, sex_encoded
- Все данные масштабированы и готовы для алгоритмов кластеризации

Выводы по преобработке данных

1. Качество данных: Исходные данные содержали значительное количество аномалий и пропусков, требующих коррекции.
2. Критические проблемы:
 - Физически невозможные значения (отрицательная длина плавника)
 - Очевидные ошибки измерений (длина плавника 5000 мм)
 - Некорректные категориальные значения
3. Эффективность обработки: Примененные методы позволили сохранить основной объем данных (344 записи) при устранении всех выявленных проблем.
4. Готовность к анализу: Данные успешно преобразованы, масштабированы и готовы для применения алгоритмов кластеризации K-means и DBSCAN.

Данные демонстрируют четкие взаимосвязи между признаками, что является благоприятным условием для кластеризации. Особенно сильная корреляция наблюдается между длиной плавника и массой тела, что может стать основой для выделения кластеров.

Применение метода K-means

Определение оптимального числа кластеров


Метод локтя и коэффициент силуэта:

Для определения оптимального числа кластеров использовались два метода: анализ "локтя" и коэффициент силуэта для K в диапазоне от 2 до 10.

Результаты подбора K:

Определение оптимального числа кластеров...

K=2: inertia=914.72, silhouette=0.442
K=3: inertia=606.30, silhouette=0.445
K=4: inertia=415.50, silhouette=0.495
K=5: inertia=308.46, silhouette=0.507
K=6: inertia=241.40, silhouette=0.512
K=7: inertia=220.62, silhouette=0.467
K=8: inertia=200.04, silhouette=0.415
K=9: inertia=187.84, silhouette=0.357
K=10: inertia=177.88, silhouette=0.346



Выбор оптимального K:

- Оптимальное число кластеров: K=6
- Коэффициент силуэта: 0.512 (умеренное качество кластеризации)

Результаты кластеризации K-means

Распределение точек по кластерам:

- Кластер 0: 78 точек (22.7%)
- Кластер 1: 65 точек (18.9%)
- Кластер 2: 77 точек (22.4%)
- Кластер 3: 58 точек (16.9%)
- Кластер 4: 29 точек (8.4%)
- Кластер 5: 37 точек (10.8%)

Качество кластеризации:


- Коэффициент силуэта: 0.512
- Кластеры распределены неравномерно, что может указывать на естественную структуру данных

Визуализация с помощью PCA

Анализ главных компонент:

- PC1 объясняет 56.7% дисперсии
- PC2 объясняет 27.7% дисперсии


- Суммарная объясненная дисперсия: 84.4% (отличный результат)



Вклад признаков в главные компоненты:

Вклад признаков в главные компоненты:

	PC1	PC2
culmen_length_mm	0.462610	0.168425
culmen_depth_mm	-0.339681	0.642530
flipper_length_mm	0.564716	-0.087458
body_mass_g	0.553299	0.057353
sex_encoded	0.213459	0.740169



Интерпретация главных компонент:


- PC1: положительно коррелирует с длиной клюва, длиной плавника и массой тела (размерные характеристики)
- PC2: положительно коррелирует с глубиной клюва и полом (морфологические и половые различия)


Анализ характеристик кластеров

Центроиды кластеров в исходном пространстве:

Анализ центроидов кластеров в исходном пространстве:

	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g	\
0	37.580769	17.575641	187.666667	3363.141026	
1	49.236923	15.646154	221.184615	5429.615385	
2	40.138961	18.962338	191.857143	4008.116883	
3	45.563793	14.237931	212.706897	4679.741379	
4	47.310345	17.706897	192.758621	3569.827586	
5	50.624324	19.270270	199.945946	3953.378378	





Интерпретация кластеров

На основе анализа центроидов можно выделить следующие группы пингвинов:

Кластер 1 (18.9%): Крупные самцы

- Наибольшая длина клюва (49.24 мм)
- Большая длина плавников (221.18 мм)
- Наибольшая масса тела (5429.6 г)
- Все особи-самцы

Кластер 5 (10.8%): Самцы с глубоким клювом

- Самая большая глубина клюва (19.27 мм)
- Большая длина клюва (50.62 мм)
- Умеренная масса тела (3953.4 г)
- Все особи-самцы

Кластер 0 (22.7%): Мелкие самки

- Наименьшая длина клюва (37.58 мм)
- Умеренная глубина клюва (17.58 мм)
- Наименьшая длина плавников (187.67 мм)
- Наименьшая масса тела (3363.1 г)
- Все особи-самки

Кластер 3 (16.9%): Крупные самки

- Большая длина клюва (45.56 мм)
- Наименьшая глубина клюва (14.24 мм)
- Большая длина плавников (212.71 мм)
- Высокая масса тела (4679.7 г)
- Все особи-самки

Кластер 2 (22.4%): Самцы среднего размера

- Умеренные размеры по всем параметрам

- Относительно большая глубина клюва (18.96 мм)

Кластер 4 (8.4%): Самки с глубоким клювом

- Большая длина клюва (47.31 мм)
- Большая глубина клюва (17.71 мм)
- Умеренная масса тела (3569.8 г)

Выводы по K-means кластеризации

1. Качество кластеризации: Умеренное (силуэт = 0.512), что типично для реальных биологических данных
2. Структура данных: Выявлено 6 естественных кластеров, соответствующих различным морфотипам пингвинов
3. Влияние пола: Пол является важным фактором - большинство кластеров содержат преимущественно особей одного пола
4. Морфологические паттерны:
 - Кластеры различаются по размерным характеристикам (длина клюва, плавников, масса)
 - Наблюдается обратная зависимость между длиной и глубиной клюва
 - Самцы в среднем крупнее самок
5. Биологическая интерпретация: Выявленные кластеры могут соответствовать различным видам или подвидам пингвинов, а также возрастным группам

Метод K-means успешно выявил естественную структуру в данных о пингвинах, разделив их на группы по размерным характеристикам и полу.

Применение метода DBSCAN


Подбор параметров DBSCAN

Метод подбора параметров:

Для определения оптимальных параметров DBSCAN использовался анализ расстояний до k-го соседа и перебор различных комбинаций eps и min_samples.

Результаты экспериментов с параметрами:

```
Подбор параметра eps...
Экспериментируем с параметрами DBSCAN:
eps=0.5, min_samples=8: кластеров=6, шум=151, силуэт=0.093
eps=0.5, min_samples=10: кластеров=4, шум=202, силуэт=0.010
eps=0.5, min_samples=12: кластеров=5, шум=227, силуэт=-0.118
eps=0.5, min_samples=15: кластеров=1, шум=314, силуэт=-1.000
eps=0.7, min_samples=8: кластеров=5, шум=32, силуэт=0.441
eps=0.7, min_samples=10: кластеров=6, шум=40, силуэт=0.410
eps=0.7, min_samples=12: кластеров=6, шум=47, силуэт=0.398
eps=0.7, min_samples=15: кластеров=6, шум=61, силуэт=0.362
eps=0.9, min_samples=8: кластеров=4, шум=4, силуэт=0.489
eps=0.9, min_samples=10: кластеров=4, шум=4, силуэт=0.489
eps=0.9, min_samples=12: кластеров=4, шум=7, силуэт=0.482
eps=0.9, min_samples=15: кластеров=4, шум=9, силуэт=0.475
eps=1.1, min_samples=8: кластеров=4, шум=1, силуэт=0.482
eps=1.1, min_samples=10: кластеров=4, шум=1, силуэт=0.482
eps=1.1, min_samples=12: кластеров=4, шум=1, силуэт=0.482
eps=1.1, min_samples=15: кластеров=4, шум=1, силуэт=0.482
```

Выбор оптимальных параметров:

- $\text{eps} = 0.9$
- $\text{min_samples} = 8$
- Коэффициент силуэта: 0.489


Результаты кластеризации DBSCAN

Статистика кластеризации:

- Найдено кластеров: 4
- Шумовых точек: 4 (1.2%)
- Коэффициент силуэта: 0.489

Распределение точек по кластерам:

- Кластер 0: 113 точек (32.8%)
- Кластер 1: 105 точек (30.5%)
- Кластер 2: 58 точек (16.9%)
- Кластер 3: 64 точек (18.6%)
- Шум: 4 точек (1.2%)



Анализ характеристик кластеров DBSCAN


Средние значения признаков по кластерам:

Средние значения признаков по кластерам DBSCAN:

	culmen_length_mm	culmen_depth_mm	flipper_length_mm \
DBSCAN_Cluster			
0	43.621239	19.044248	194.460177
1	40.054286	17.580000	189.104762
2	45.563793	14.237931	212.706897
3	49.075000	15.625000	221.046875

	body_mass_g	sex_encoded
DBSCAN_Cluster		
0	3986.725664	1.0
1	3411.904762	0.0
2	4679.741379	0.0
3	5419.921875	1.0

<Figure size 1200x600 with 0 Axes>



Интерпретация кластеров DBSCAN:

Кластер 3 (18.6%): Крупные самцы

- Наибольшая длина клюва (49.08 мм)
- Большая длина плавников (221.05 мм)
- Наибольшая масса тела (5419.92 г)
- Все особи-самцы

Кластер 2 (16.9%): Крупные самки с тонким клювом

- Большая длина клюва (45.56 мм)
- Наименьшая глубина клюва (14.24 мм)
- Большая длина плавников (212.71 мм)
- Высокая масса тела (4679.74 г)
- Все особи-самки

Кластер 0 (32.8%): Самцы среднего размера

- Умеренные размеры по всем параметрам
- Относительно большая глубина клюва (19.04 мм)
- Все особи-самцы

Кластер 1 (30.5%): Мелкие самки

- Наименьшая длина клюва (40.05 мм)

- Умеренная глубина клюва (17.58 мм)
- Наименьшая длина плавников (189.10 мм)
- Наименьшая масса тела (3411.90 г)
- Все особи-самки



Сравнение и интерпретация результатов

Сводное сравнение методов

Сравнительная таблица результатов:

СВОДКА РЕЗУЛЬТАТОВ КЛАСТЕРИЗАЦИИ:

Метод	Кластеров	Шум	Силуэт
K-means	6	0	0.512
DBSCAN	4	4	0.489




Анализ согласованности кластеров

Таблица сопряженности:

Таблица сопряженности кластеров K-means и DBSCAN:

col_0	-1	0	1	2	3
row_0					
0	1	0	77	0	0
1	1	0	0	0	64
2	1	76	0	0	0
3	0	0	0	58	0
4	1	0	28	0	0
5	0	37	0	0	0



Выявленные соответствия:

- K-means кластер 2 $\approx$ DBSCAN кластер 0 (76 точек)
- K-means кластер 3 $\approx$ DBSCAN кластер 2 (58 точек)
- K-means кластер 1 $\approx$ DBSCAN кластер 3 (64 точек)
- K-means кластер 0 $\approx$ DBSCAN кластер 1 (77 точек)

Сравнительный анализ методов

K-means:

- Преимущества:
 1. Предсказуемое число кластеров
 2. Быстрая работа и простая реализация
 3. Лучшее качество на этих данных (силуэт = 0.512)
- Недостатки:
 4. Требуется задания числа кластеров заранее
 5. Чувствителен к выбросам и начальной инициализации
 6. Предполагает сферическую форму кластеров

DBSCAN:

- Преимущества:
 1. Автоматическое определение числа кластеров
 2. Устойчивость к выбросам (выделил 4 шумовые точки)
 3. Способность находить кластеры произвольной формы
- Недостатки:

1. Чувствительность к параметрам `eps` и `min_samples`
2. Сложность подбора оптимальных параметров
3. Немного худшее качество (силуэт = 0.489)

Анализ шумовых точек DBSCAN

Характеристики шумовых точек:

- Количество: 4 точки (1.2% от общего числа)
- Средние значения: промежуточные между кластерами
- Не являются статистическими выбросами по отдельным признакам
- Вероятно, представляют переходные формы между основными морфотипами

Биологическая интерпретация

Выявленные морфотипы пингвинов:

1. Крупные самцы (DBSCAN кластер 3 / K-means кластер 1)
 - Наибольшие размеры тела и клюва
 - Вероятно, доминирующие особи
2. Крупные самки с тонким клювом (DBSCAN кластер 2 / K-means кластер 3)
 - Специализированная морфология клюва
 - Возможно, адаптация к иному типу питания
3. Самцы среднего размера (DBSCAN кластер 0 / K-means кластер 2)
 - Наиболее распространенный тип
 - Умеренные размеры
4. Мелкие самки (DBSCAN кластер 1 / K-means кластер 0)
 - Наименьшие размеры
 - Явный половой диморфизм

Общие выводы по реальным данным

1. Качество кластеризации: Оба метода показали хорошие результаты (силуэт > 0.45), что подтверждает наличие естественной кластерной структуры в данных.
2. Согласованность методов: несмотря на разное количество кластеров, оба метода выявили сходные группировки пингвинов по размерным характеристикам и полу.
3. Биологическая значимость: Выявленные кластеры соответствуют реальным морфологическим вариациям пингвинов, связанным с половым диморфизмом и, возможно, видовыми различиями.
4. Практическая применимость: для данного набора данных K-means показал slightly лучшее качество, но DBSCAN предоставил дополнительную информацию о шумовых точках.

Оба метода успешно справились с задачей кластеризации реальных биологических данных, демонстрируя свою применимость для анализа морфологических характеристик животных.

5. Вывод

В ходе выполнения лабораторной работы было освоено практическое применение методов кластеризации данных на реальных примерах. Были изучены и применены два ключевых алгоритма - K-means и DBSCAN, каждый из которых продемонстрировал свои сильные стороны в различных условиях. На искусственно сгенерированных данных оба метода показали отличные результаты, успешно выделяя заранее заданные кластеры, при этом DBSCAN дополнительно проявил способность к идентификации шумовых точек. При работе с реальными данными о пингвинах была проведена полная процедура предобработки, включая обработку пропусков, выбросов и масштабирование признаков, что подчеркивает важность этапа подготовки данных в реальных задачах.

Ссылка на GitHub с Google Collab:

https://github.com/ndanilova/Data_Analysis/tree/main/lab2